

1. Motivation

Les établissements scolaires peinent à identifier les élèves en difficulté avant la publication des résultats finaux. Un modèle prédictif permettrait d'intervenir tôt et d'améliorer l'accompagnement pédagogique.]

2. Question de recherche

« Peut-on prédire la note finale d'un élève à partir de son temps d'étude hebdomadaire, de ses échecs passés, de ses absences et de ses notes aux trimestres précédents ? »

3. Méthode

Le modèle de régression linéaire s'écrit, sous forme matricielle :

$$\hat{y} = X_b \cdot \theta$$

où X_b est la matrice des observations (avec colonne de biais), θ le vecteur des paramètres et $\hat{y}$ les valeurs prédites. Les paramètres optimaux sont obtenus directement grâce à l'Équation Normale :


$$\theta^* = (X_b^T X_b)^{-1} X_b^T y$$

Le pipeline implémenté en NumPy pur comprend 5 étapes :

1. Construction de la matrice de design X_b (ajout de la colonne de biais)
2. Vérification de l'inversibilité de $X_b^T X_b$ (rang, déterminant, conditionnement)
3. Résolution de l'Équation Normale pour obtenir θ^*
4. Prédiction : $\hat{y} = X_b \cdot \theta^*$
5. Évaluation : MSE et RMSE sur les ensembles train et test


4. Données

Source : Kaggle/Google Dataset — Nombre d'observations : [n = 345]



5. Résultats

Valeurs réelles vs valeurs prédites



Coefficients estimés θ^*

- θ_0 (constante / biais) = 0.24 → note de base estimée quand toutes les variables valent 0
- θ_1 (Temps_Etude_Hebdo) = 0.02 → chaque heure d'étude supplémentaire augmente la note prédite de 0.02 point(s)
- θ_2 (Nombre_Echecs_Passes) = 0.027 → chaque échec passé supplémentaire fait baisser la note de 0.027 point(s)
- θ_3 (Nombre_Absences) = -0.01 → chaque absence supplémentaire fait baisser la note de -0.01 point(s)
- θ_4 (Note_Premier_Trimestre) = 0.12 → chaque point de plus au 1er trimestre augmente la note prédite de 0.12 point(s)
- θ_5 (Note_Deuxieme_Trimestre) = 0.86 → chaque point de plus au 2e trimestre augmente la note prédite de 0.86 point(s)

Qualité du modèle

RMSE = [0.826146r] → « En moyenne, le modèle se trompe de [0.82 /20] sur ses prédictions. »

6. Limites et perspectives

- Variables comportementales non capturées (motivation, soutien familial, conditions d'étude)
- Relation potentiellement non linéaire entre absences et note finale
- Modèle non généralisable à d'autres établissements sans nouvelle validation
- Piste : tester une régression Ridge/Lasso ou un modèle non linéaire